何思韵
语音数据标注 / ASR 评测
2026

语言任务样本展示页

以下四个模块对应语音数据与语言模型训练中的典型任务，覆盖「**数据构建 → 标注 → 模型评估 → 偏差归因**」全链路。 所有数据来自本人参与的田野调查与真实项目，非虚构案例。

模块一 ASR 训练数据构建与转写误差分析

来源：国家社科基金重大项目子课题（2022.07–2022.10 项目参与）+ 本科毕业论文延伸研究（2022.11–2023.04，个人整理）

任务：将核心词汇转写为粤语写法、拼音及 IPA 注音，构建结构化语音样本集

规模：3000+ 条词语的音频切分、转写与音素对齐　　**工具**：Praat、IPA 转写表、Whisper（抽样验证）

示例（节选）：人工转写与模型输出的逐条比对

音频编号	人工转写结果	Whisper 输出	差异点	语言注释
ASR_GDFS_001	kʰeoi44 fan52 hel53 ok55	kʰei25 kʰeoi44 fan52 tou44 ŋo23 ok55	hel53→tou44 ∅→ŋo23	口音偏差导致识别出错；鼻音导致增音

可迁移任务结构

- 语音合成 拼音–IPA 映射任务（语音合成基础训练）
- 音系 音变识别任务（音位差异分类训练）
- ASR 输出纠偏任务（语音模型微调辅助样本）
- 多模态 多语种词汇对齐任务（词义 / 发音多模态建模）

能力体现

- 能把「人类语音的模糊表达」转化为可训练的语言标签，具备结构化能力
- 掌握基础音系知识、IPA 转写规范、粤语调值与音变模式
- 能基于语言学专业知识，构建适用于 ASR 系统的标注体系

语言任务样本展示页

模块二 LLM Prompt 构建与输出纠偏

任务类型：Prompt 编写 + 输出校对 + 情绪 / 意图 / 风格标注

起点：在使用大模型协助编辑时，观察到模型常无法保留原句的情绪质感与风格语调，输出"太工具化"或"太模糊"。于是反复调整输入结构、记录有效与无效的触发模式，逐步形成对模型语言偏差的识别感。

原始人类输入	Prompt 目标	初版输出	问题发现	纠偏后输出	情绪标签
我有时候觉得不是我不想说，是说的那个回路根本没打开。	用生理隐喻模拟"表达系统未激活"的内在体验	我有点不愿意表达，可能是不想面对问题。	用"回避"替代了"表达机制失效"；忽略回路隐喻；风格单调	像是有人偷偷把那个"开口的按钮"藏了起来，我一直在找，但没有反应。	沉默、冻结、轻微困惑 风格：身体化语言 / 神经断路隐喻
我认为自己不能忍受他人用审视的方式看我，哪怕他们说的是好话。	表达"被称赞时的不适感"，强调被凝视的不自由，不使用否定式	我不喜欢别人夸我，这让我觉得很别扭。	情绪标签粗糙（"别扭"太轻）；未呈现"赞美即控制"；缺少文化 / 关系隐喻层	他们说我是个值得被喜欢的人，我笑着点头，但心里像被什么捏了一下。	羞耻、被凝视、控制下的顺从 风格：隐性抵抗 / 多义性表达

能力体现

- 能构建 Prompt 指令、识别模型输出问题、完成校对与风格调整，同时完成语言结构标注
- 将 Prompt 编排与输出评估标准化，形成适用于「风格重建 / 语义纠偏 / 结构提炼」的语言调控能力

这份能力的来源不是课程，而是长期使用中积累的「生成语言判断力」—— 从语言使用者转向语言建模参与者的关键一步。

语言任务样本展示页

模块三 语言结构标准化：自然语言意图解析

来源：广东省汇智项目管理有限公司 | 招标部项目助理（2024.04–2025.10）

背景：甲方常提供结构混乱、表达模糊的语言需求，我负责将其转化为逻辑清晰、语义一致的技术文档。该过程高度贴合语言模型训练中的「意图解析 + 格式重写」任务。

原始输入（自然语言）	人工拆解结果	标准化语言输出（技术文案）
"要一个信息管理系统，最好可以分析，后期可以再扩展……"	**关键词提取**：信息管理系统、分析功能、可扩展性 **隐含需求提炼**：权限控制、数据可视化、模块化结构	"建设一套具备用户信息管理、数据查询与统计分析功能的信息系统，支持模块化扩展，满足数据安全与权限控制要求。"

任务标签

类型：自然语言意图解析 → 格式化指令转写　|　**技能点**：结构补全 / 语义补强 / 风格重写 / 需求泛化 / 情感标注

可用于：LLM Prompt 样本设计、结构化输入构建、意图识别模型训练

工具协同流程

- 使用大模型协助初步摘要与格式重组
- 结合 WPS 统一格式与术语，输出规范文本
- 通过人工修订确保语义完整与执行可读性

模拟扩展任务（可用于训练集构建）

输入「帮我把这段招标语写规范点」→ 输出任务对：**[原始需求] → [标准表达]**，可应用于 Prompt 精调、风格迁移、业务语言合成任务。

该模块展示的是「非结构语言 → 结构化建模语料」的转换能力，具备为语言模型提供真实任务样本的构建与审校经验。

语言任务样本展示页

模块四 ASR 评测实战：Whisper 在粤语字表朗读场景的适用性

数据：粤语田野调查录音《江曾摄》408 秒；《江摄》字表 54 条，其中 **41 条**成功采集读音，**13 条**因发音人无法引导而缺失（评测中整行剔除，避免虚增漏识）

系统：Whisper small（faster-whisper 1.2.1，int8 量化，language=zh）

方法：VAD 分段 → 逐段转写 → 与字表对齐 → 双口径 CER 计算 → 音系错误归因

三个发现

1. **输出多样性塌缩**

   41 条参考字涵盖 **20 种不同音节、10 类声母**（p / pʰ / ʦ / ʦʰ / s / k / h / m / t / ŋ）；模型在该区间输出的 58 个单元中，**43 个是同一个字「膀」**，去重后仅 6 种。本应呈现明显差异的音节序列，被压成单一字形。

2. **同音字归并，导致字面 CER 系统性虚高**

   字表「邦」→ 输出「帮」（bong1 / bong1）、「庞」→「旁」（pong4 / pong4）、「窗」→「枪」（coeng1 / coeng1）：**字面全错，音值全对**。方言调查按「音」列字，同一个音底下一组同音字，模型只保留一个字形，因此仅用汉字错误率会严重高估错误。

3. **通用粤拼词表不适用于本方言点**

   字表记「江 / 扛 / 豇」均为 kɔŋ 51（见母读 k-），而标准粤拼为 **gong1**（g-）。以通用词典作判定基准，会把本来正确的判成错误 —— **评测基准必须使用田野采集的 IPA 记音。**

方法建议：双口径 CER 框架

口径	计算方式	用途
字面 CER	严格按汉字比对（编辑距离 ÷ 参考字数）	与行业常规指标对齐
音值 CER	同音字判为正确，只计真音错	反映实际可用性

两个口径的差值 = 同音字归并造成的假错误比例。错误再按声母 / 韵母 / 声调 / 增字 / 漏识细分归因。

局限（如实说明）

- 逐段对应关系尚未逐条人工复核，结论基于序列整体统计
- 样本为单一方言点、单一发音人，不可外推至粤语整体
- 未做参数对比实验（model size、language=zh / yue）

该模块的核心价值：识别出「字面错、音值对」这一只有语言学背景才能发现的评测陷阱，并据此提出双口径评测方案。